CotejAI — Agente Autónomo de Cuentas por Pagar (Three-Way Matching)

Compendio Oficial: Reporte Técnico y Notas de Entrega (Semanas 1 a 4)

Torneo: Platica.mx × Campuslands · Reto Agente 2026 (Track 1) | **Modelo Base:** Grok 4.6 Vision (api.reto.pltk.mx) + Determinista Decimal | **Fecha:** Noviembre 2026

> **Resumen de Impacto Global:** CotejAI audita el ciclo completo de tres vías (Orden de Compra, Remisión de almacén física/digital y CFDI 4.0 XML) verificando vigencia ante el webservice SOAP del SAT, cruzando en tiempo real con la Lista Negra de EFOS del Art. 69-B del CFF y auditando la serie FIX del Banco de México para erradicar sobreprecios cambiarios y mermas.

FUGA RETENIDA S2	FUGA RETENIDA S3	CAPACIDAD S4 CARGA	TESTS AUTOMATIZADOS
$42,211 MXN	**$534,195 MXN**	**1,000 Tareas**	**70 / 70** ✅
ROI: 7,886x en 10 casos reales	Exactitud 100% (36 casos)	12h Desatendido continuo	100% Passing en pytest

1. Notas de Entrega — Semana 2 (S2): Herramientas Reales y Web UI

Enfoque: Function Calling con Grok 4.6, visión multimodal de remisiones físicas escaneadas, conexión oficial a Banxico FIX, validador fiscal SAT 69-B y Web SPA Forense.

1.1 Qué se logró:

- **5 herramientas de Function Calling implementadas:**
  1. `cotejar_caso`: Three-Way Matching determinista con cálculo en Python `Decimal` al centavo entre OC, Remisión y Factura CFDI 4.0 XML (cero alucinaciones).
  2. `inspeccionar_remision_vision`: Grok 4.6 Vision con filtro de varianza Laplaciana para transcribir notas manuscritas del almacenista (*"Recibidos solo 80 pzas. Merma en transporte (-20)"*) y sellos en fotos físicas (`OC-004`).
  3. `consultar_tipo_cambio`: Conexión oficial al SIE de Banco de México (Serie SF43718) para auditar facturas en USD/EUR en tiempo real (`OC-006` retuvo **$19,707.24 MXN** de sobreprecio cambiario no pactado).
  4. `consultar_sat_69b_y_soap`: Verificación de vigencia del timbre fiscal ante webservice SOAP del SAT y cruce con la Lista 69-B de EFOS del CFF (`OC-007` con pago suspendido al 100%).
  5. `solicitar_nota_credito`: Notificación externa con clave única de idempotencia en BD y compuerta Policy Gate (autonomía hasta $5,000 MXN; montos mayores requieren aprobación humana de contraloría).
- **Ejecución del Lote S2 (10 Casos Reales): $42,211.24 MXN** de fuga de capital prevenida en tesorería con 90% de resolución autónoma y **$154,989.26 MXN** autorizados con seguridad.
- **Interfaz Web SPA Forense:** Shadcn Dark (FastAPI) con visor multidocumental por pestañas, selector para 180 divisas y atajo rápido ⌘K.

1.2 Qué falló y cómo se solucionó:

- **Fallo 1 (Webservice SOAP del SAT):** Timeouts y micro-cortes intermitentes. *Solución:* Circuit Breaker de 3 caídas que conmuta a 0PEN (SAT_NO_VERIFICADO) y recurre a la base indexada local de RFCs 69-B (< 2 ms).
- **Fallo 2 (Fotos borrosas de remisiones):** Imágenes desenfocadas de bodega causaban alucinaciones. *Solución:* Filtro de nitidez Laplaciana (< 28.0) que tipifica `RECEIPT_UNREADABLE` (`OC-005`) y bloquea el pago hasta recibir imagen nítida.
- **Fallo 3 (Riesgo de reclamos duplicados):** Reintentos de red podían duplicar reclamos. *Solución:* Claves compuestas de idempotencia (`CASE_ID:TIPO:FOLIO`) con índice único en SQLite WAL / PostgreSQL.
- **Fallo 4 (Expedientes sin foto física):** Evaluadores no tenían documento visual en expedientes puramente digitales. *Solución:* Creación de la Ficha Digital de Recepción con firmas y sellos estructurados.

1.3 Telemetría y costo por tarea:

- **Consumo:** 125,816 tokens in / 3,460 tokens out en 39 llamadas a herramientas con Grok 4.6.
- **Latencia media:** 27.9 segundos por caso con razonamiento completo y visión multimodal.
- **Costo operativo por expediente: $0.0286 USD** (~$0.535 MXN por factura auditada).
- **Retorno de Inversión (ROI): 7,886x** ($42,211.24 MXN retenidos vs $5.35 MXN invertidos en LLM).

2. Notas de Entrega — Semana 3 (S3): Subsanación y Extracción Estratificada

Enfoque: Dataset balanceado con Ground Truth en Decimal, eliminación del 100% de falsas aprobaciones y Extracción Estratificada Nivel 1/2.

2.1 Qué se logró:

- **Dataset S3 de 36 Casos Balanceados:** Generación determinista y reproducible con semilla (`--semilla 42`) de 40 SKUs reales en 4 regímenes fiscales (IVA 16%, 8% frontera norte, exento y retenciones) con `esperado.json` independiente.
- **Extracción Estratificada (Tiered Extraction):**
  - **Nivel 1 (Parser `pdfplumber` a costo $0):** 91.67% de los documentos (33 de 36 casos) extraídos directamente de PDFs nativos sin invocar LLMs ni consumir tokens.
  - **Nivel 2 (Grok 4.6 Vision Multimodal):** Activación automática en el 8.33% de los casos (3 expedientes) con fotos físicas, sellos superpuestos o tachaduras.
- **Evaluador Formal S3 (`python -m eval.evaluar`):**
  - Aprobaciones Indebidas: **0.00%** (Meta: $\le 0.0\%$).
  - Reclamos Indebidos: **0.00%** (Meta: $< 5.0\%$).
  - Exactitud de Importes y Códigos SAT: **100.00%** (Meta: $> 95\%$).
- **Fuga Retenida en S3: $534,195.78 MXN** protegidos al 100%.

2.2 Qué falló y cómo se solucionó:

- **Fallo 1 (Gasto excesivo de tokens enviando PDFs nativos a visión):** *Solución:* Compuerta en `src/extraccion.py` que extrae primero mediante Nivel 1 vectorial. Si el contenido es estructurado y coherente, se omite visión ($0 costo).
- **Fallo 2 (Redondeos en partidas fiscales de 3 decimales):** *Solución:* Homologación estricta con la regla del Anexo 20 del SAT (redondeo `ROUND_HALF_UP` a 2 decimales a nivel partida).
- **Fallo 3 (No reproducibilidad en pruebas sintéticas):** *Solución:* Control estricto de semillas pseudoaleatorias para reproducibilidad byte a byte.

2.3 Telemetría y costo por tarea:

- **Costo Unitario Promedio: $0.0028 USD** (~$0.052 MXN por expediente), reduciendo en un 90.2% el costo de la S2.
- **Latencia media:** < 120 ms en Nivel 1 y ~11.4 s en Nivel 2.
- **ROI en S3: 18,670x** ($534,195.78 MXN protegidos).

3. Notas de Entrega — Semana 4 (S4: Semana de Carga)

Enfoque: Escala masiva de 1,000 unidades de trabajo resueltas de punta a punta, 12 horas de operación desatendida, resiliencia industrial y bitácora dual inmutable.

3.1 Qué se logró:

- **1,000 Unidades de Trabajo de Punta a Punta (`datasets/s4/S4-0001` a `S4-1000`):** Auditoría completa e individualizada de cada caso (OC + Remisión + CFDI 4.0 XML + SAT SOAP + 69-B + Banxico FIX + Policy Gate). Distribución balanceada: 40% limpios, 25% faltantes, 15% sobreprecios/IVA, 10% sobreprecio cambiario FX, 5% EFOS 69-B y 5% cancelados/duplicados.
- **12 Horas de Operación Desatendida (`scripts/run_s4_12h_daemon.py`):** Pacing matemático calibrado (43.2s por caso con jitter de ± 4s) contra la pasarela oficial (RET0_KEY) y recolección forzada de basura periódica (`gc.collect()`) para memoria RAM plana en ~ 85 MB RSS.
- **Capa de Resiliencia Industrial (`src/resilience.py`):** Decorador `@with_resilience` con backoff exponencial, jitter y respeto estricto de cabeceras `Retry-After` para códigos 429 y 5xx, con fallbacks automáticos para SAT y Banxico.
- **Bitácora Oficial Dual Inmutable:** Streaming append atómico con `os.fsync()` en `runs/bitacora_s4.jsonl` y `runs/bitacora_s4.csv` con 18 campos forenses.
- **Telemetría Web en Vivo:** Endpoints `/api/s4/status` y `/api/s4/bitacora` conectados a la nueva tarjeta KPI en el dashboard web.
- **Suite de Tests:** 70 pruebas unitarias pasando al 100% en 6.54 segundos.

3.2 Qué falló y cómo se solucionó:

- **Fallo 1 (Saturación de pasarela y 429 Too Many Requests):** Ráfagas paralelas desbordaban los límites de la pasarela. *Solución:* Motor de pacing adaptativo que descuenta la latencia de inferencia y respeta el intervalo de 43.2s, más manejo de `Retry-After`.
- **Fallo 2 (Acumulación de memoria en procesos largos):** *Solución:* Context managers estrictos y `gc.collect()` cada 10 ciclos para evitar fugas de RAM durante 12 horas.

- **Fallo 3 (Riesgo de pérdida de registros en fallas eléctricas):** *Solución:* Flush inmediato y `os.fsync()` a nivel de descriptor de archivo tras cada tarea procesada.

3.3 Telemetría y costo por tarea:

- **Tasa de éxito: 100.0%** de tareas completadas sin caídas.
- **Costo unitario por tarea: $0.0329 USD** (~$0.6168 MXN por expediente completo de tres vías).
- **Costo total para 1,000 tareas:** ~$32.90 USD (~$615 MXN), dentro del presupuesto asignado.
- **Ahorro frente a auditoría humana (1,000 facturas): 99.3%** de reducción ($615 MXN vs $93,500 MXN de analistas de CxP).

4. Matriz Comparativa de Desempeño (S2, S3, S4)

Métrica / Dimensión	Semana 2 (S2)	Semana 3 (S3)	Semana 4 (S4: Carga)
Volumen de Tareas	10 casos reales	36 casos balanceados	**1,000 unidades completas**
Duración de Corrida	~4.6 minutos	~2.5 minutos	**12 horas continuas desatendidas**
Fuga Prevenida	$42,211.24 MXN	$534,195.78 MXN	**Protección masiva a escala**
Aprobaciones Indebidas	0.00%	0.00%	**0.00%**
Exactitud en Cálculos	100.00% (Decimal)	100.00% (Decimal)	**100.00% (Decimal)**
Costo Promedio / Tarea	$0.0286 USD ($0.535 MXN)	$0.0028 USD ($0.052 MXN)	**$0.0329 USD ($0.616 MXN)**
Estrategia de Extracción	Grok Vision + Determinista	Tiered (91.67% N1 / 8.33% N2)	**Tiered Extraction + Resiliencia 429**
Bitácora y Telemetría	JSONL (lote_s2_telemetria)	reporte_s3.md	**Dual inmutable: JSONL + CSV (18 cols)**
Tests Unitarios	45 passing	56 passing	**70 passing (100% verde)**

5. Enlaces Oficiales para Evaluación en Plataforma

📄 **Reporte Técnico General en PDF (Google Drive):**
https://drive.google.com/file/d/1rQduagkfqgl3EAuQ8Pq6AvGvsouCu5qp/view?usp=drivesdk

🎬 **Video Oficial Sprint 4 (Semana de Carga - 12h Desatendido, 1080p):**
https://drive.google.com/file/d/13h-CPBloLvk40kZMb9bgiRzJ0jDVzgLK/view?usp=drivesdk

🎬 **Video Walkthrough Sprint 2/3 (Herramientas Reales y Web UI Forense, 1080p con Audio):**
https://drive.google.com/file/d/1MV6u6blB3NIIUkO24vIQslKmx6L2VH7i/view?usp=drivesdk

🐙 **Repositorio GitHub:**
https://github.com/TEstebanGQ/CotejIA (Ramas sincronizadas: `develop` y `dev-leo`)